평균에 대하여

1.환경준비

• 라이브러리 불러오기

```
import pandas as pd
import numpy as np
import random as rd

import matplotlib.pyplot as plt
import seaborn as sns
import scipy.stats as spst
```

2.분산과 표준편차

- 한 집단을 설명하기 위해서
- 그 집단 안에서 대푯값으로 평균을 구할 때
- 값들이 평균으로부터 얼마나 벗어나 있는지(이탈도, deviation)를 나타내는 값.
 - 예: 우리 반 수학 성적의 평균이 91, 표준편차는 10

```
In [3]: a = np.array([180,173,165,166,171])

print(f'평균 : {a.mean()}')
print(f'분산 : {a.var()}')
print(f'표준편차 : {a.std()}')
```

평균 : 171.0 분산 : 29.2

표준편차 : 5.403702434442518

3.평균비교

- 평균이 믿을만 한지는 오차로 평가해야 합니다.
 - 표준편차
 - 표준오차

평균 38.6, 표준편차 17.5는 집단 a를 설명(대표)하는 숫자 입니다.

(1) 표준오차(SE, standard error)

- 표준오차는 표준편차와 다른 개념입니다. (표준 편차와 비교하는 개념이 아닙니다!)
- 우선 표본(의) 평균을 이해해야 합니다.

- 표본을 뽑아내는(표집, sampling) 목적은, 모집단을 추정하기 위함 입니다.
 - 표본평균을 계산한다는 의미는, 표본의 평균으로 모집단의 평균을 **추정**하기 위함 입니다.(**추정치**)
 - 표본의 평균을 계산하면, 표본 자체의 평균이라는 의미가 아니라, 모평균을 표본으로 추정한 평균치 입니다.
 - 그래서 표본평균 하면 항상 모평균을 의식해야 합니다.
- 그런데 표본평균은 모평균과 완전히 일치할 수는 없습니다.
- 이 오차를 표준오차 라고 합니다.
- 표준오차 공식 : s/√n
 - 샘플의 표준 편차 : s
 - 데이터 건수: n
- 표준 오차로 부터 신뢰구간을 계산하게 됩니다.
- 몇가지 기호에 대해서

기호	의미
μ	모평균
σ^2	모분산
$ar{X}$	표본평균
s ²	표본분산

(2) 95% 신뢰구간

• 모집단을 하나 준비합니다.

```
In [4]: # 임의의 모집단을 하나 만듭시다.
pop = [round(rd.normalvariate(172, 7),1) for i in range(800000)]

In [11]: # 우리는 모집단을 알 수 없지만.
# 전지적 분석가 시점에서 살짝 살펴봅시다. (보고 나서 못 본 것으로 합시다.ㅎㅎ)

plt.figure(figsize=(10,6))
sns.histplot(pop, bins = 100)
plt.axvline(np.mean(pop), color = 'r')
plt.text(np.mean(pop)+1, 30000, f'pop mean : {np.mean(pop).round(3)}', color = 'r')
plt.show()
```

24. 3. 14. 오후 2:51

pop mean: 168.249

- 표본 조사를 합니다.
 - 50명을 임의로 샘플링 해서
 - 표본의 평균과, 표준 오차, 신뢰구간을 계산해 봅시다.

```
In [12]: # 표본조사를 합니다. 50
s1 = rd.sample(pop, 50)
s1 = pd.Series(s1)
round(s1.mean(),3)

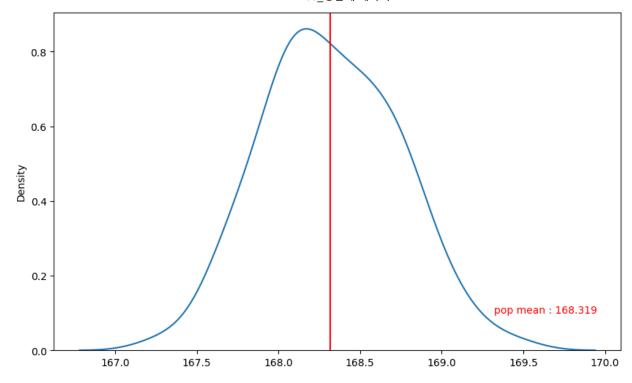
Out[12]: 169.081

In [13]: x_mean = []
for i in range(100):
    s1 = rd.sample(pop, 50)
    s1 = pd.Series(s1)
    x_mean.append(round(s1.mean(),3))

x_mean
```

```
[168.179,
Out[13]:
            168.101,
            168.65,
            167.99,
            168.679,
            169.207,
            168.202,
            168.883,
            168.689,
            168.456,
            167.754,
            168.35,
            168.845,
            168.56,
            168.16,
            168.643,
            168.553,
            168.692,
            168.452,
            168.045,
            168.326,
            168.675,
            168.769,
            167.856,
            168.702,
            168.432,
            169.444,
            167.992,
            168.132,
            167.641,
            168.441,
            168.458,
            168.493,
            168.799,
            168.794,
            167.278,
            168.031,
            168.932,
            168.527,
            168.29,
            167.982,
            168.3,
            168.15,
            168.478,
            168.215,
            168.213,
            168.37,
            168.015,
            167.848,
            168.717,
            168.08,
            167.826,
            167.812,
            168.513,
            168.264,
            168.624,
            168.223,
            168.186,
            168.343,
            167.643,
```

```
06_평균에 대하여
           168.611,
           167.72,
           168.38,
           168.11,
           168.193,
           167.483,
           168.13,
           169.025,
           168.82,
           167.622,
           168.357,
           168.338,
           167.98,
           168.467,
           167.832,
           168.474,
           168.04,
           167.905,
           167.758,
           168.886,
           168.291,
           169.152,
           167.978,
           168.02,
           168.663,
           168.011,
           167.951,
           168.084,
           168.858,
           168.509,
           168.8,
           167.706,
           168.117,
           167.669,
           168.682,
           169.037,
           169.008,
           168.211,
           168.007,
           168.145]
           plt.figure(figsize=(10,6))
In [14]:
           sns.kdeplot(x_mean)
           plt.axvline(np.mean(x_mean), color = 'r')
           plt.text(np.mean(x_mean)+1, 0.1, f'pop mean : {round(np.mean(x_mean),3)}', color = 'r')
           plt.show()
```



```
# 95% 신뢰구간
In [15]:
          s1.mean() - (1.96 * s1.sem()), s1.mean() + (1.96 * s1.sem())
```

(167.31112756760393, 168.979672432396) Out[15]:

• 표본평균의 신뢰구간과 모평균을 비교해 봅시다.

```
# 모평균은?
In [16]:
         np.mean(pop)
         168.24887711228877
```

Out[16]:

- 95% 신뢰구간에 대한 실험을 해 봅시다.
 - 샘플조사를 100번 수행합니다.
 - 그때마다 신뢰구간을 계산한 후
 - 그 중 몇번이 모평균을 포함하는지 확인해 봅시다.
 - 95% 신뢰구간이라면, 100번 중 95번은 모평균을 포함해야 합니다.

```
In [17]: # 100번 샘플링
          samples = { 'id' : [], 'value' : []}
          for i in range(100) :
              samples['id'] += [i]* 100
              samples['value'] += rd.sample(pop,100)
          samples = pd.DataFrame(samples)
          samples.shape
          (10000, 2)
Out[17]:
```

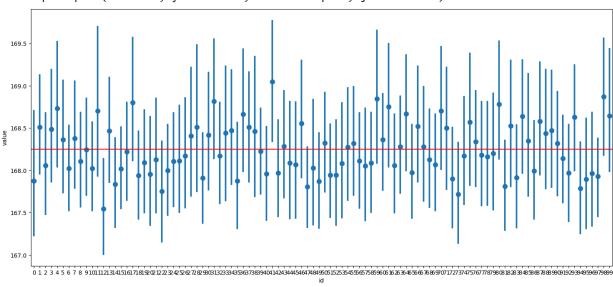
```
In [18]: # errorbar 라는 차트 입니다.
# 신뢰구간, 표준오차 구간을 시각화 하는 방법입니다.

plt.figure(figsize = (18, 8))
sns.pointplot(x = 'id', y = 'value', data = samples, join = False)
plt.axhline(np.mean(pop), color = 'r')
plt.show()
```

C:\Users\User\AppData\Local\Temp\ipykernel_5152\2126722236.py:5: UserWarning:

The `join` parameter is deprecated and will be removed in v0.15.0. You can remove the line bet ween points with `linestyle='none'`.

sns.pointplot(x = 'id', y = 'value', data = samples, join = False)



위 그래프에 대한 해석

- x축은 100번 시도에 대한 순번(인덱스)
- y축은 모평균(빨간 선)을 추정하기 위한 샘플의 평균과, 신뢰구간 표시

4.중심극한 정리

• 표본이 클수록 표집분포는 정규분포에 가까워 진다.

(1) 정규분포 실험

• 임의의 모집단을 하나 만듭니다.

```
In [5]: pop = [round(rd.expovariate(.3)+165,2) for i in range(10001)]
```

- ① 모집단으로 부터 데이터 n개 짜리 표본집합을 뽑아 표본평균을 계산합니다.
- ② ①번 작업을 m번 반복하여 얻은 표본평균 m개로 분포를 그려봅니다.

```
In [8]: # 표본집합의 크기 ==> 데이터의 건수
n = 100

# 표본의 갯수 ==> 집합 건수
m = 200

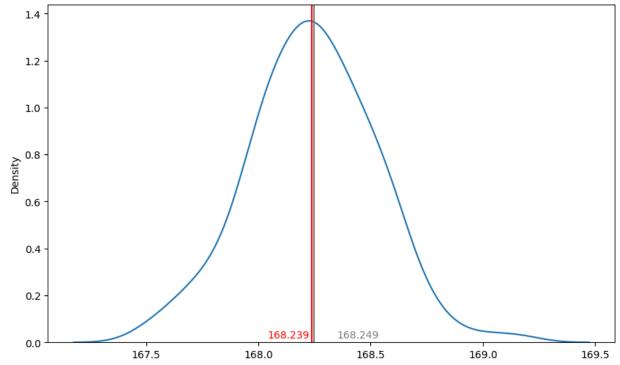
sample_mean = [np.mean(rd.sample(pop,n)) for i in range(m)]

plt.figure(figsize=(10,6))
sns.kdeplot(sample_mean)

plt.axvline(x=np.mean(sample_mean), color = 'red') #표본평균들의 평균
plt.axvline(x=np.mean(pop), color = 'grey') # 모평균

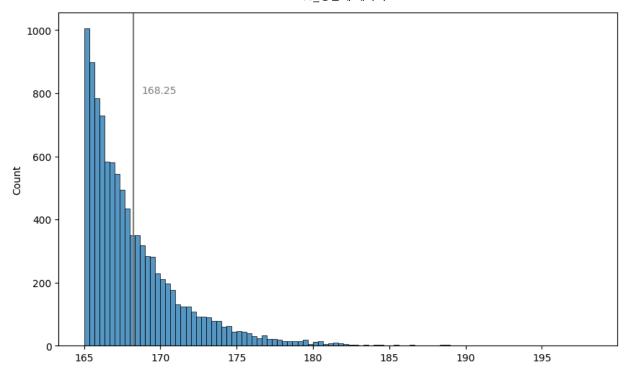
plt.text(np.mean(sample_mean)--2, 0.02, round(np.mean(sample_mean),3), color = 'red') #표본평균
plt.text(np.mean(pop)+-1,0.02, round(np.mean(pop),3), color = 'grey') #모평균

plt.show() # show
```



• 그렇다면, 모집단은 어떤 분포일까?

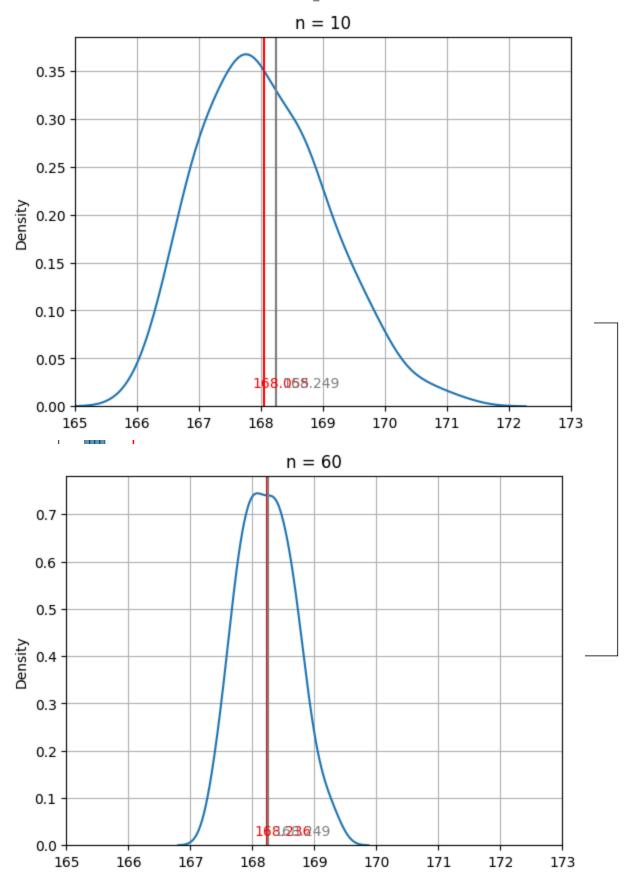
```
In [7]: plt.figure(figsize=(10,6)) #설정
sns.histplot(pop, bins = 100)
plt.axvline(x=np.mean(pop), color = 'grey') # 모평균
plt.text(np.mean(pop)+.5, 800, round(np.mean(pop),2), color = 'grey')
plt.show()
```

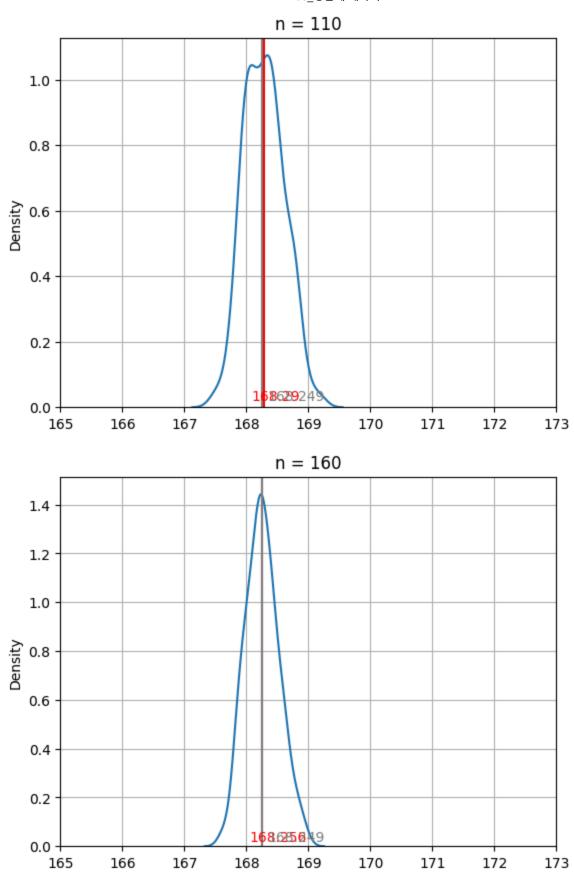


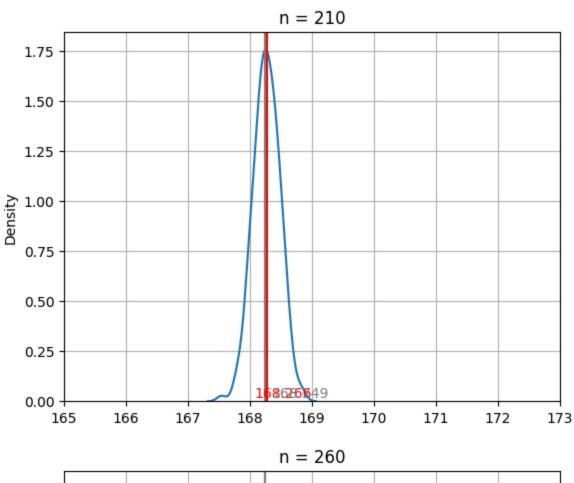
In []:

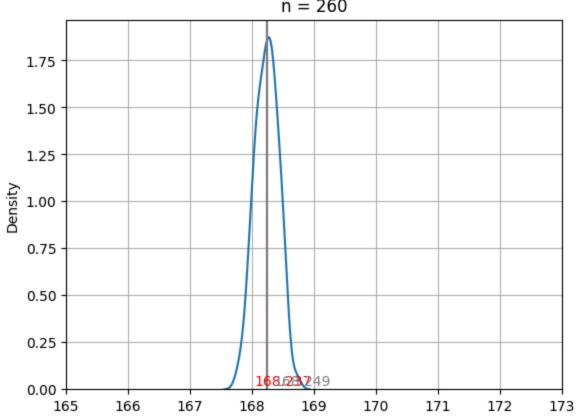
(2) 표본의 크기에 따른 정규분포

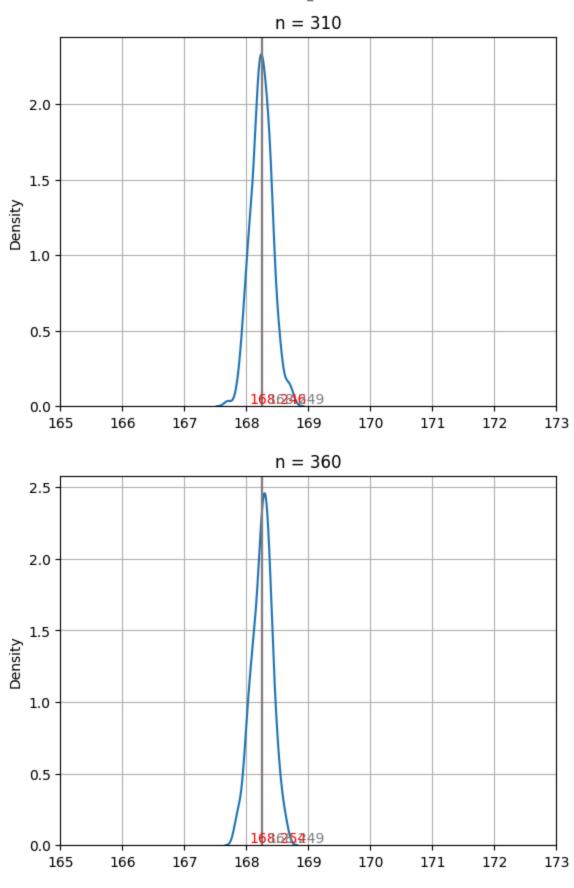
```
# 표본집합의 크기
In [9]:
       n = 100
       # 표본의 갯수
       m = 200
       for n in range(10,2001, 50):
          sample_mean = [np.mean(rd.sample(pop,n)) for i in range(m)]
          plt.title(f'n = {n}')
          sns.kdeplot(sample_mean)
          plt.axvline(x=np.mean(sample_mean), color = 'red') #표본평균들의 평균
          plt.axvline(x=np.mean(pop), color = 'grey') # 모평균
          plt.text(np.mean(pop)+.1,0.02, round(np.mean(pop),3), color = 'grey') #모평균
          plt.xlim(165, 173)
          plt.grid()
          plt.show() # show
```

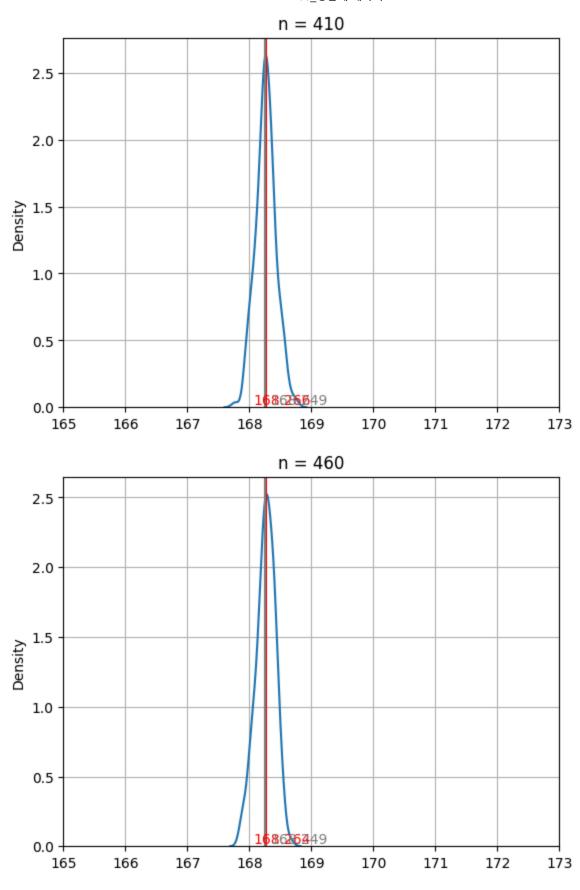


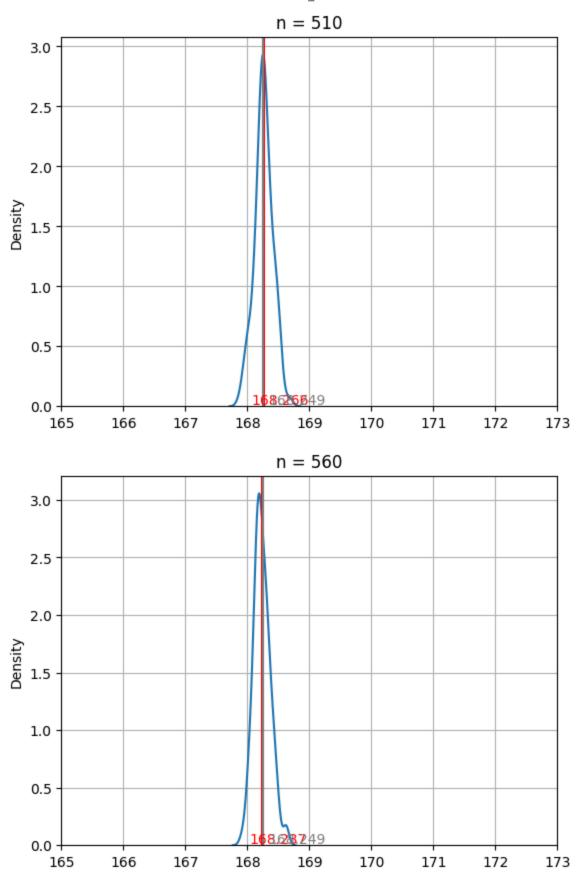


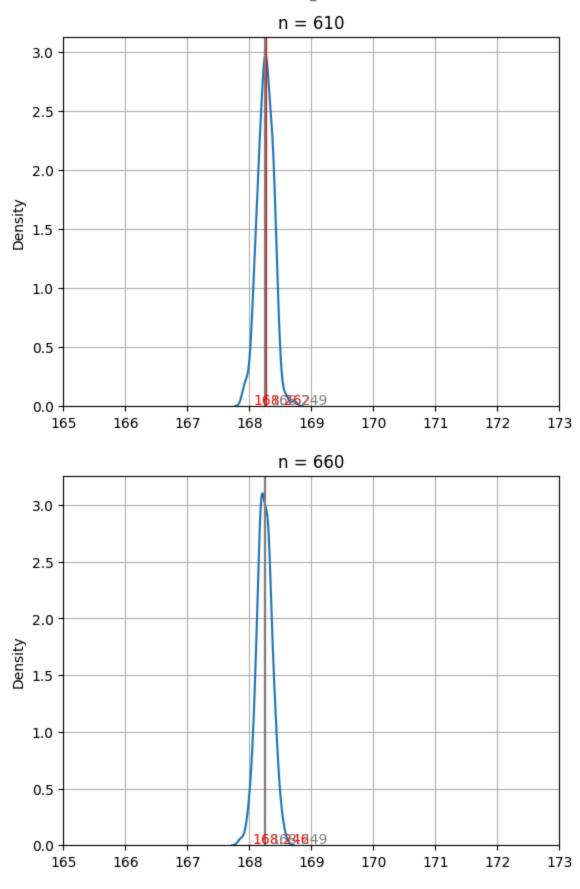


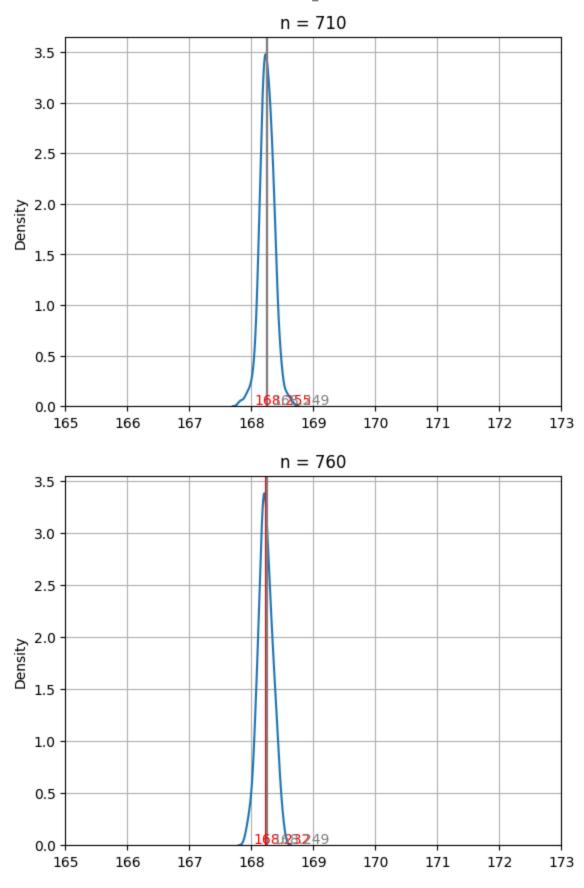


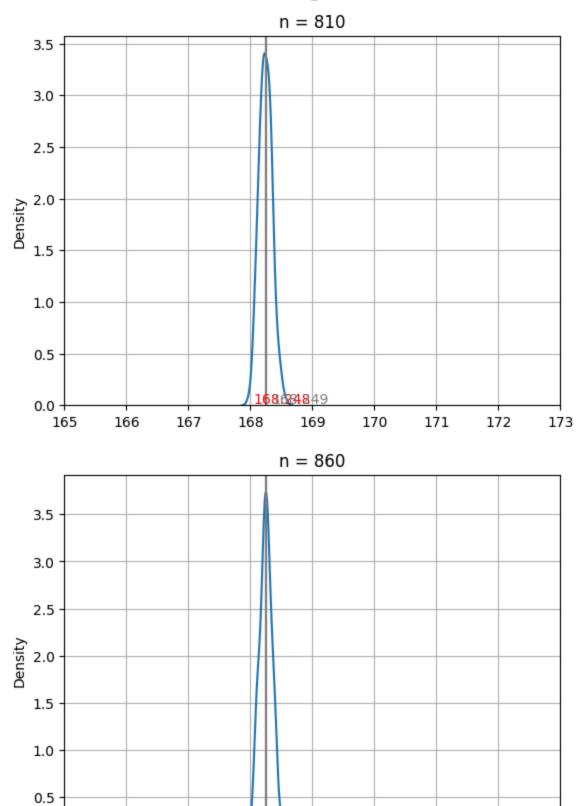




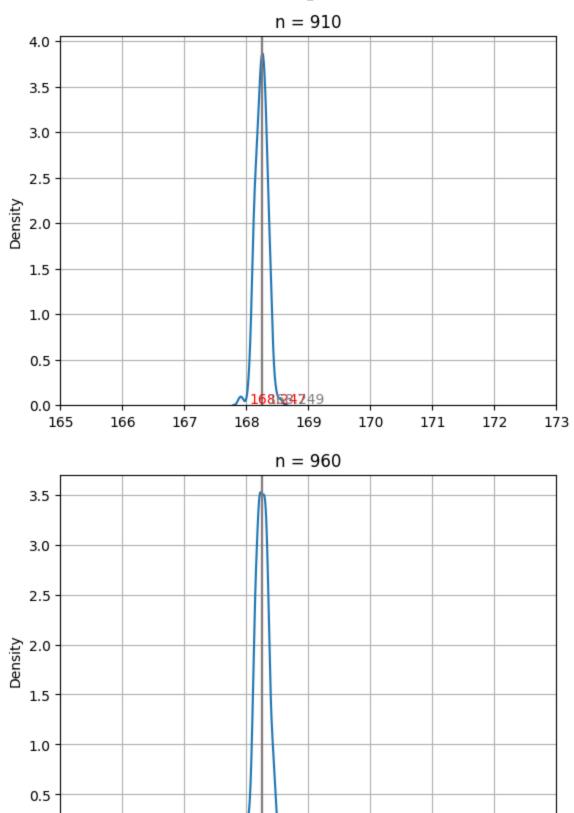




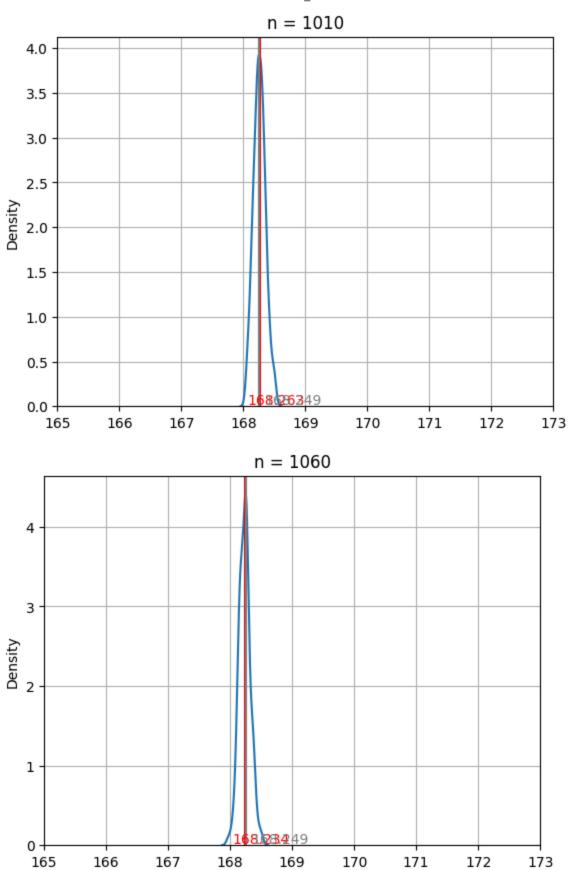


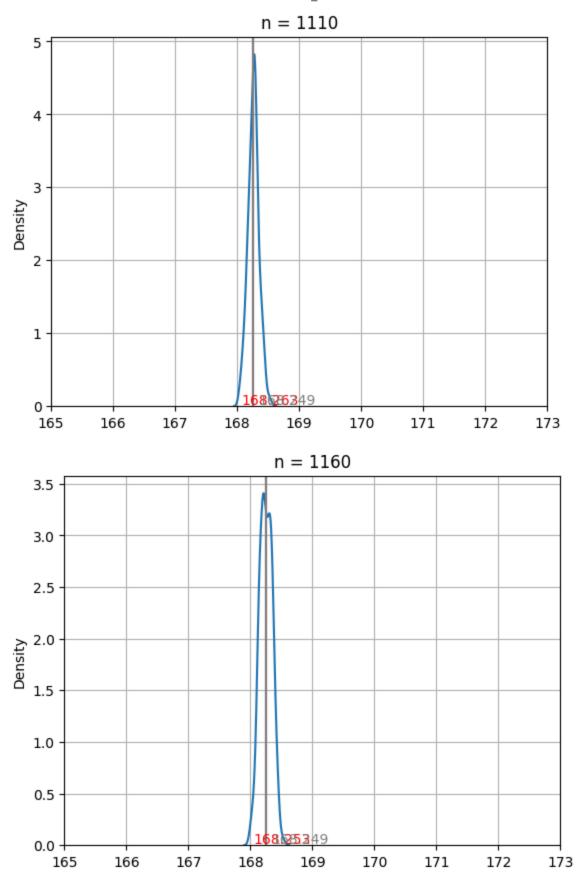


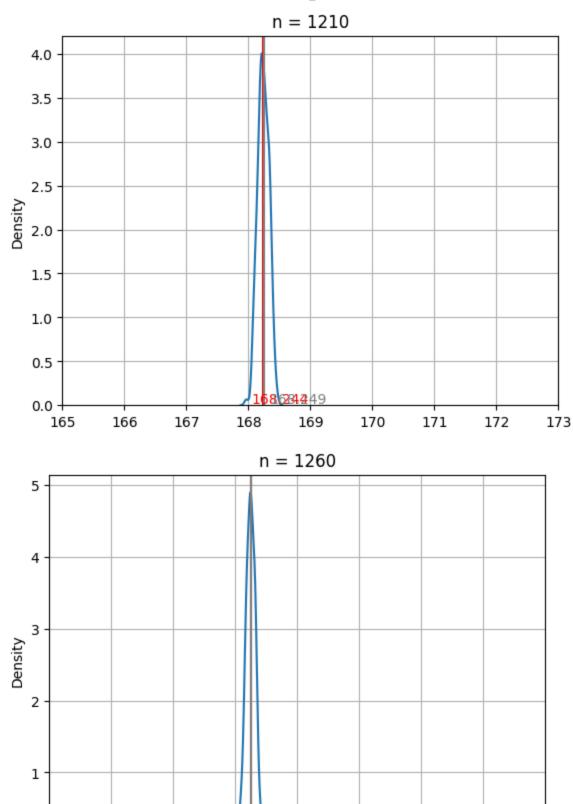
0.0 +



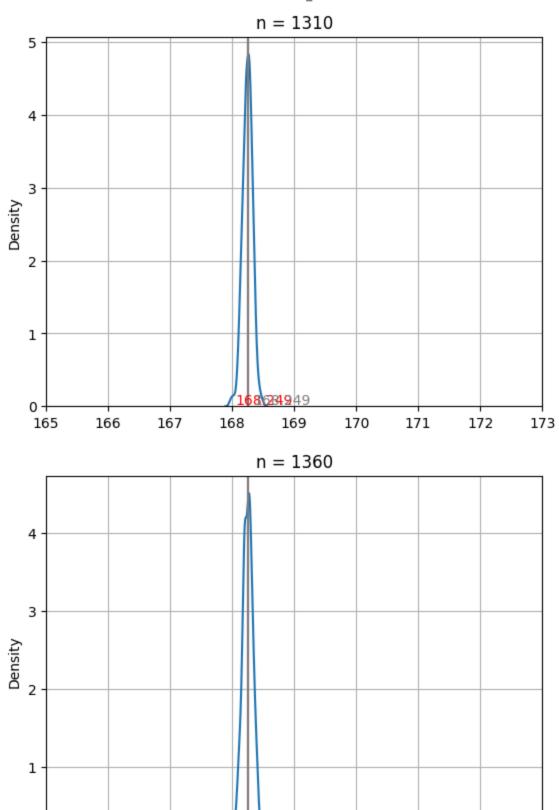
0.0 +



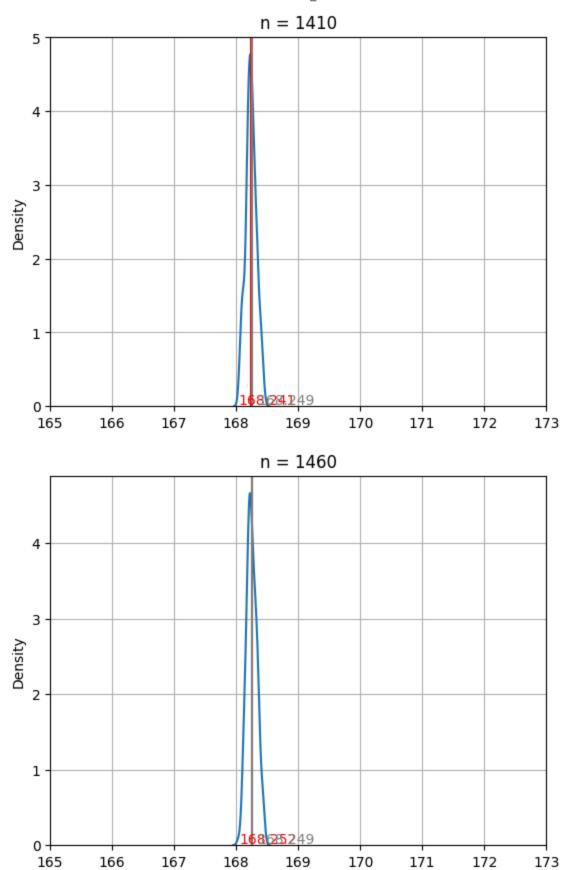


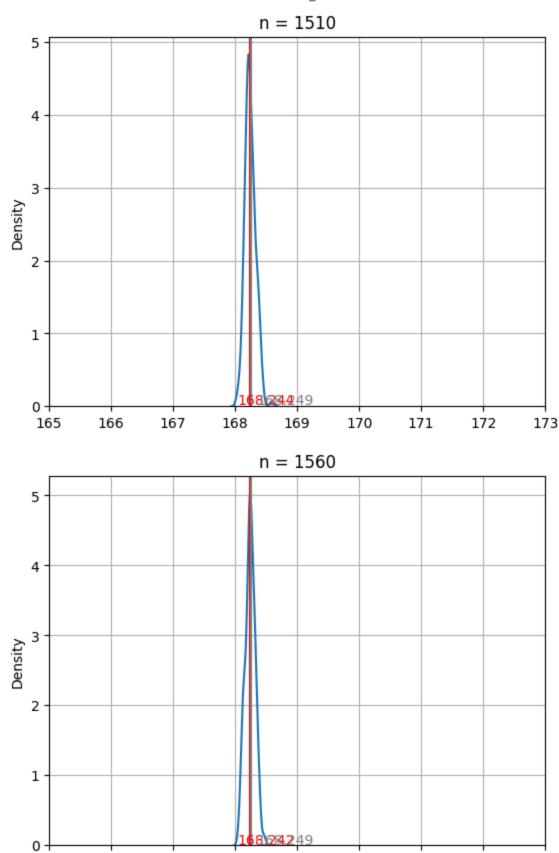


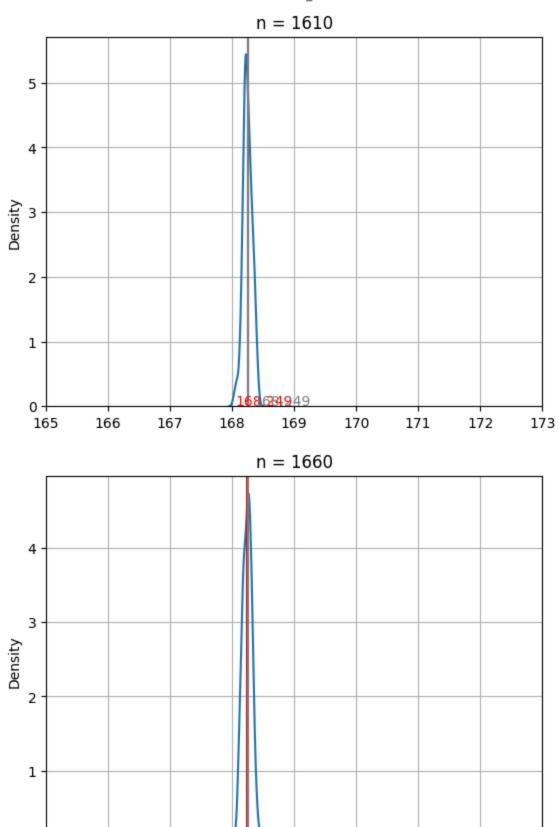
0 | 165



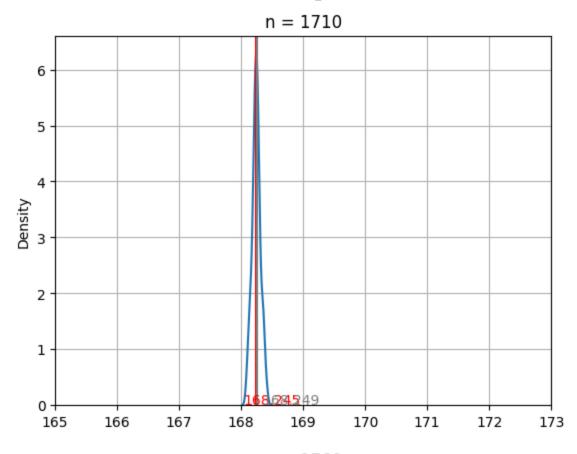
0 | 165

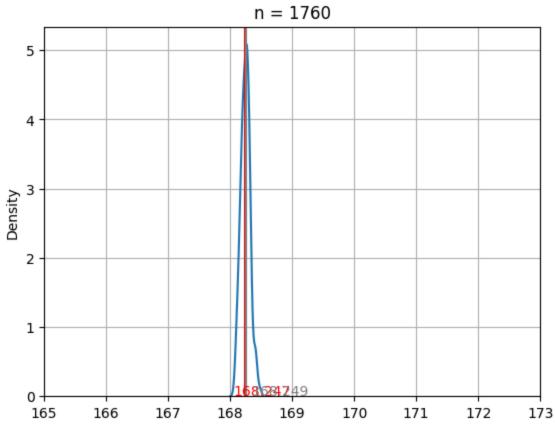


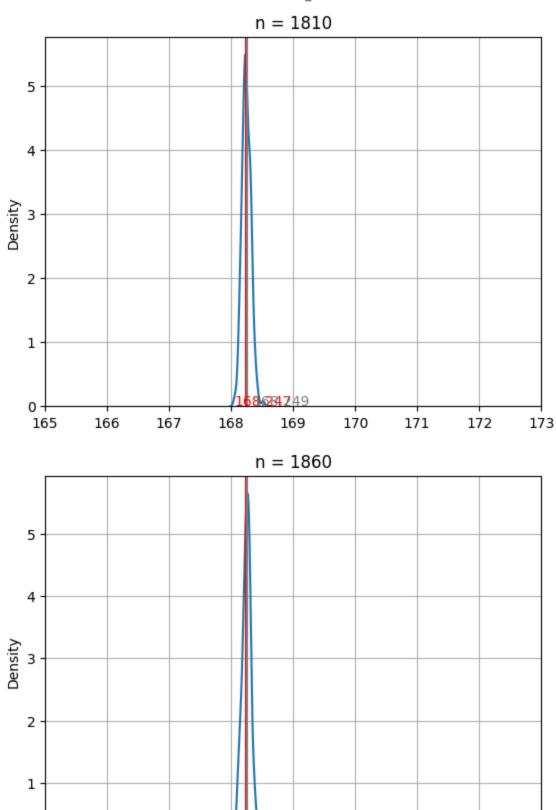


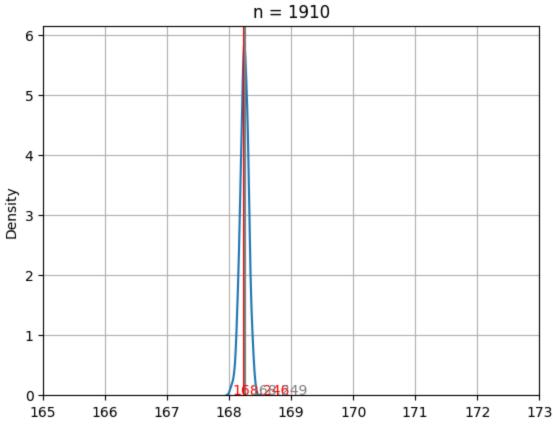


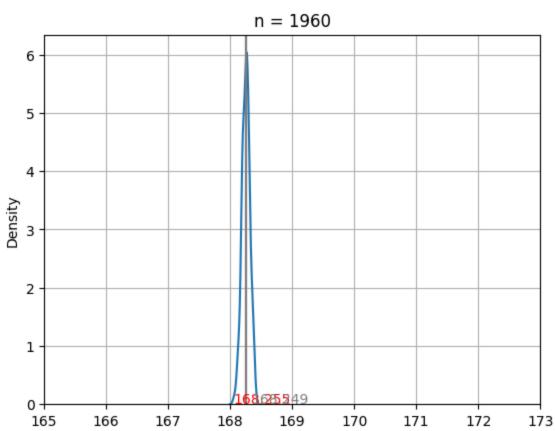
0 | 165







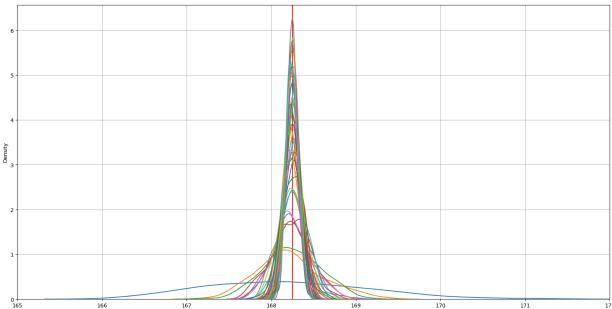




```
plt.figure(figsize = (20,10))
plt.axvline(x=np.mean(pop), color = 'red') # 모평균
plt.xlim(165, 172)
plt.grid()

for n in range(10,2001, 50 ) :
    sample_mean = [np.mean(rd.sample(pop,n)) for i in range(m)]
    sns.kdeplot(sample_mean)

plt.show()
```



In []: