Machine Learning with Python

Life is too short, You need Python

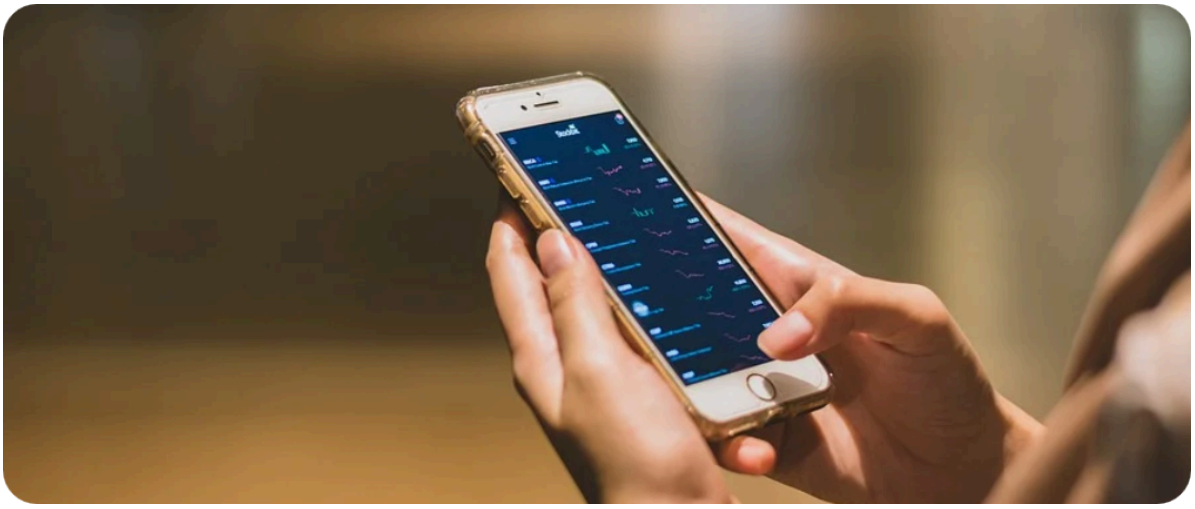

실습 내용

- Mobile 데이터로 모델링합니다.
- Decision Tree 알고리즘으로 모델링합니다.

1.환경 준비

- 기본 라이브러리와 대상 데이터를 가져와 이후 과정을 준비합니다.

In [1]:
```
# 라이브러리 불러오기
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import warnings

warnings.filterwarnings(action='ignore')
%config InlineBackend.figure_format='retina'
```

In [2]:
```
# 데이터 읽어오기
path = 'https://raw.githubusercontent.com/jangrae/csv/master/mobile_cust_churn.csv'
data = pd.read_csv(path)
```

2.데이터 이해

- 분석할 데이터를 충분히 이해할 수 있도록 다양한 탐색 과정을 수행합니다.

In [3]:
```
# 상위 몇 개 행 확인
data.head()
```

Out[3]:

	id	COLLEGE	INCOME	OVERAGE	LEFTOVER	HOUSE	HANDSET_PRICE	OVER_15MINS_CALLS_PER_I
0	1	0	31953	0	6	313378	161	
1	2	1	36147	0	13	800586	244	
2	3	1	27273	230	0	305049	201	
3	4	0	120070	38	33	788235	780	
4	5	1	29215	208	85	224784	241	

데이터 설명

- COLLEGE: 대학 졸업여부
- INCOME: 연수입
- OVERAGE: 월평균 초과사용 시간(분)
- LEFTOVER: 월평균 잔여시간비율(%)
- HOUSE: 집값
- HANDSET_PRICE: 스마트폰 가격
- OVER_15MINS_CALLS_PER_MONTH: 월평균 장기통화(15분이상) 횟수
- AVERAGE_CALL_DURATION: 평균 통화 시간
- REPORTED_SATISFACTION: 만족도 설문조사 결과
- REPORTED_USAGE_LEVEL: 사용도 자가진단 결과
- CONSIDERING_CHANGE_OF_PLAN: 향후 변경계획 설문조사 결과
- CHURN: 이탈(번호이동) 여부 (Target 변수)

In [4]:
```
# 변수 확인
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20000 entries, 0 to 19999
Data columns (total 13 columns):
 #   Column                        Non-Null Count  Dtype
---  ------                        --------------  -----
 0   id                            20000 non-null  int64
 1   COLLEGE                       20000 non-null  int64
 2   INCOME                        20000 non-null  int64
 3   OVERAGE                       20000 non-null  int64
 4   LEFTOVER                      20000 non-null  int64
 5   HOUSE                         20000 non-null  int64
 6   HANDSET_PRICE                 20000 non-null  int64
 7   OVER_15MINS_CALLS_PER_MONTH   20000 non-null  int64
 8   AVERAGE_CALL_DURATION         20000 non-null  int64
 9   REPORTED_SATISFACTION         20000 non-null  object
 10  REPORTED_USAGE_LEVEL          20000 non-null  object
 11  CONSIDERING_CHANGE_OF_PLAN    20000 non-null  object
 12  CHURN                         20000 non-null  object
dtypes: int64(9), object(4)
memory usage: 2.0+ MB
```

In [5]:
```
# 기술통계 확인
data.describe()
```

Out[5]:

	id	COLLEGE	INCOME	OVERAGE	LEFTOVER	HOUSE	HANDS
count	20000.000000	20000.000000	20000.000000	20000.000000	20000.000000	20000.000000	200
mean	10000.500000	0.502400	80281.447750	85.979550	23.898650	493155.264250	3
std	5773.647028	0.500007	41680.586319	85.992324	26.816645	252407.884692	2
min	1.000000	0.000000	20007.000000	-2.000000	0.000000	150002.000000	1
25%	5000.750000	0.000000	42217.000000	0.000000	0.000000	263714.250000	2
50%	10000.500000	1.000000	75366.500000	59.000000	14.000000	452259.500000	3
75%	15000.250000	1.000000	115881.750000	179.000000	41.000000	702378.000000	5
max	20000.000000	1.000000	159983.000000	335.000000	89.000000	999996.000000	8

In [6]:
```
# target 값 개수 확인
data['CHURN'].value_counts()
```

Out[6]:
```
CHURN
STAY     10148
LEAVE     9852
Name: count, dtype: int64
```

In [7]:
```
# 상관관계 확인
data.corr(numeric_only=True)
```

Out[7]:

	id	COLLEGE	INCOME	OVERAGE	LEFTOVER	HOUSE	H
id	1.000000	-0.005557	0.003686	-0.006050	0.006069	0.011347	
COLLEGE	-0.005557	1.000000	0.011122	-0.003091	-0.003925	-0.000217	
INCOME	0.003686	0.011122	1.000000	0.000458	0.006515	-0.010964	
OVERAGE	-0.006050	-0.003091	0.000458	1.000000	-0.003123	0.002412	
LEFTOVER	0.006069	-0.003925	0.006515	-0.003123	1.000000	0.006530	
HOUSE	0.011347	-0.000217	-0.010964	0.002412	0.006530	1.000000	
HANDSET_PRICE	-0.007838	0.009950	0.727200	0.000324	0.004004	-0.007756	
OVER_15MINS_CALLS_PER_MONTH	0.001254	-0.007205	0.002136	0.770557	-0.010411	0.007410	
AVERAGE_CALL_DURATION	-0.005830	-0.001490	-0.007219	0.000653	-0.660285	-0.009359	

3.데이터 준비

- 전처리 과정을 통해 머신러닝 알고리즘에 사용할 수 있는 형태의 데이터를 준비합니다.

1) 변수 제거

In [8]:
```
# 제거 대상: id
drop_cols = ['id']

# 변수 제거
data = data.drop(drop_cols, axis=1)

# 확인
data.head()
```

Out[8]:

	COLLEGE	INCOME	OVERAGE	LEFTOVER	HOUSE	HANDSET_PRICE	OVER_15MINS_CALLS_PER_MON
0	0	31953	0	6	313378	161	
1	1	36147	0	13	800586	244	
2	1	27273	230	0	305049	201	
3	0	120070	38	33	788235	780	
4	1	29215	208	85	224784	241	

2) x, y 분리

In [9]:
```
# Target 설정
target = 'CHURN'

# 데이터 분리
```

```
x = data.drop(target, axis=1)
y = data.loc[:,target]
```

3) 가변수화

In [12]:
```
# 가변수화 대상: REPORTED_SATISFACTION, REPORTED_USAGE_LEVEL, CONSIDERING_CHANGE_OF_PLAN
dumm_cols = ['REPORTED_SATISFACTION', 'REPORTED_USAGE_LEVEL', 'CONSIDERING_CHANGE_OF_PLAN']

# 가변수화
x = pd.get_dummies(x, columns=dumm_cols, drop_first=True, dtype=int)

# 확인
x
```

Out[12]:

	COLLEGE	INCOME	OVERAGE	LEFTOVER	HOUSE	HANDSET_PRICE	OVER_15MINS_CALLS_PER_
0	0	31953	0	6	313378	161	
1	1	36147	0	13	800586	244	
2	1	27273	230	0	305049	201	
3	0	120070	38	33	788235	780	
4	1	29215	208	85	224784	241	
...	...	...	...	...	...	...	
19995	0	153252	0	23	368403	597	
19996	1	107126	71	82	237397	609	
19997	0	78529	0	66	172589	275	
19998	0	78674	47	41	572406	288	
19999	0	124697	0	0	845575	808	

20000 rows × 20 columns

4) 학습용, 평가용 데이터 분리

In [13]:
```
# 모듈 불러오기
from sklearn.model_selection import train_test_split

# 7:3으로 분리
x_train, x_test, y_train, y_test= train_test_split(x, y, test_size=0.3, random_state=1)
```

4.모델링

- 본격적으로 모델을 선언하고 학습하고 평가하는 과정을 진행합니다.

In [55]:
```
# 1단계: 불러오기
from sklearn.tree import DecisionTreeClassifier
from sklearn.metrics import confusion_matrix, classification_report
```

In [56]:
```
# 2단계: 선언하기
model = DecisionTreeClassifier(max_depth=5, random_state=1)
```

In [58]:
```
# 3단계: 학습하기
model.fit(x_train, y_train)
```

Out[58]:
```
DecisionTreeClassifier(max_depth=5, random_state=1)
```

In [59]:
```
# 4단계: 예측하기
y_pred = model.predict(x_test)
```

In [60]:
```
# 5단계: 평가하기
print(confusion_matrix(y_test, y_pred))
print(classification_report(y_test, y_pred))
```

```
[[2077  858]
 [ 953 2112]]
              precision    recall  f1-score   support

       LEAVE       0.69      0.71      0.70      2935
        STAY       0.71      0.69      0.70      3065

    accuracy                           0.70      6000
   macro avg       0.70      0.70      0.70      6000
weighted avg       0.70      0.70      0.70      6000
```

5.기타

- 기타 필요한 내용이 있으면 진행합니다.

In [61]:
```
# 시각화 모듈 불러오기
from sklearn.tree import export_graphviz
from IPython.display import Image

# 이미지 파일 만들기
export_graphviz(model,                                  # 모델 이름
                out_file='tree.dot',                    # 파일 이름
                feature_names=list(x),                  # Feature 이름
                class_names=['die', 'survived'],        # Target Class 이름 (분류인 경우만 지정
                rounded=True,                           # 둥근 테두리
                precision=2,                            # 불순도 소숫점 자리수
                max_depth=3,                            # 실제로 표시할 트리 깊이
                filled=True)

# 파일 변환
!dot tree.dot -Tpng -otree.png -Gdpi=300

# 이미지 파일 표시
Image(filename='tree.png')
```

Out[61]:

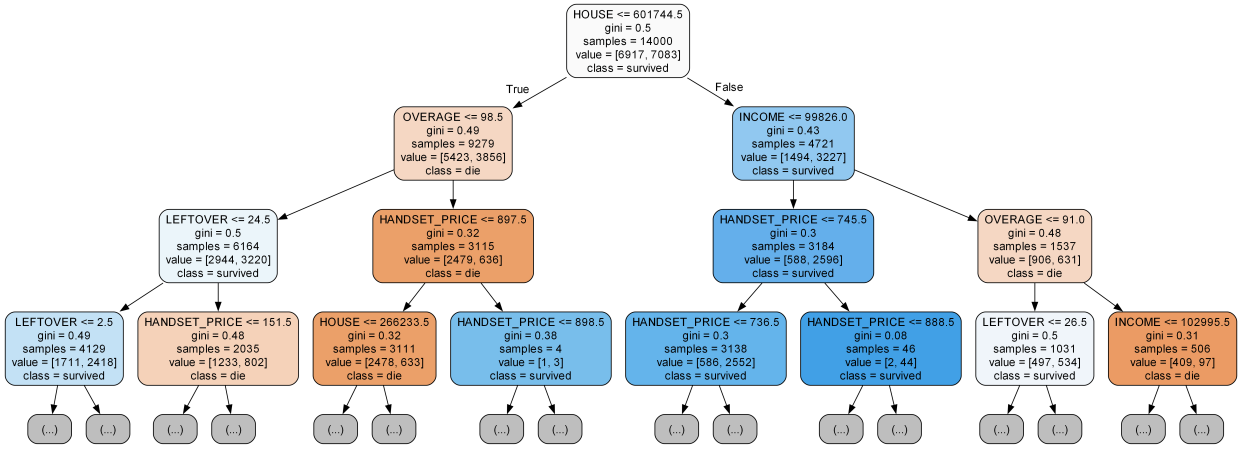

In [62]:

```
# 변수 중요도 시각화
plt.barh(y=list(x), width=model.feature_importances_)
plt.show()
```

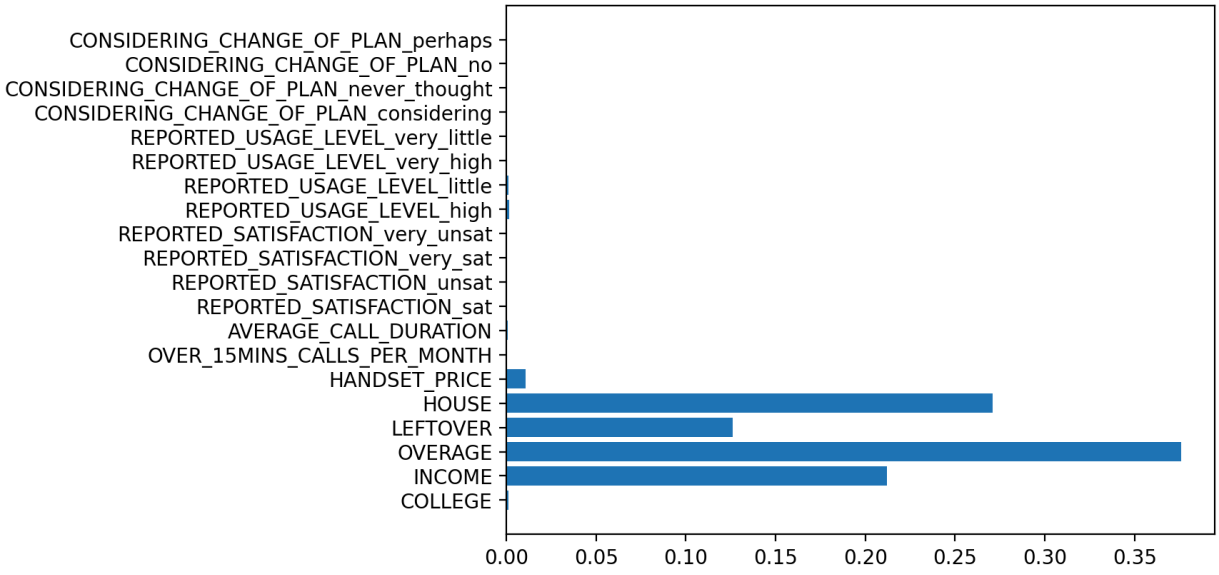

In [63]:

```
# 데이터프레임 만들기 #정렬
df = pd.DataFrame()
df['feature'] = list(x)
df['importance'] = model.feature_importances_
df.sort_values(by='importance', ascending=True, inplace=True)

# 0 미만 제거 # 0 미만 의미 없음
df = df.loc[df['importance'] > 0]

# 시각화
plt.figure(figsize=(5, 5))
plt.barh(df['feature'], df['importance'])
plt.show()
```

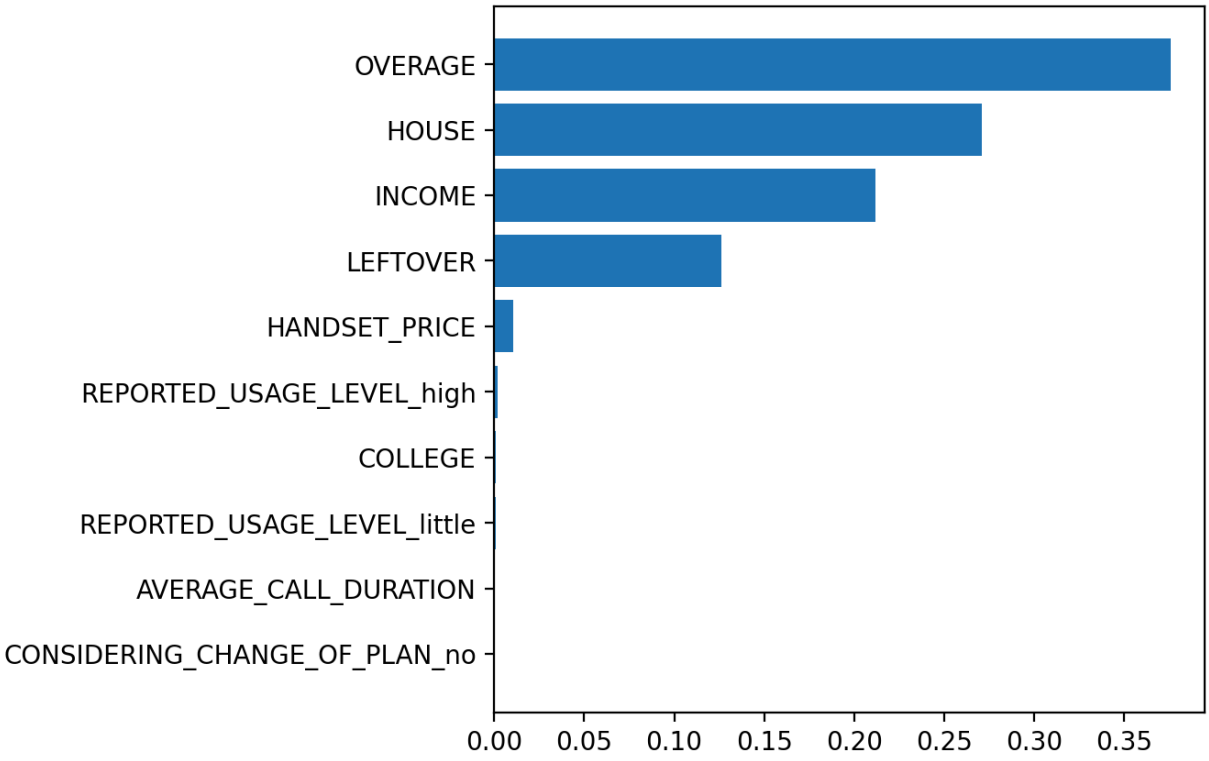
OVERAGE
HOUSE
INCOME
LEFTOVER
HANDSET_PRICE
REPORTED_USAGE_LEVEL_high
COLLEGE
REPORTED_USAGE_LEVEL_little
AVERAGE_CALL_DURATION
CONSIDERING_CHANGE_OF_PLAN_no
0.00
0.05
0.10
0.15
0.20
0.25
0.30
0.35

In [ ]: