

KT AIVLE School

1일차 정리


전체 Process(CRISP-DM)

무엇이 문제인가?

- ✓ 비즈니스 **문제정의**
- ✓ 데이터분석 방향, 목표
- ✓ 초기 **가설 수립**
 $x \rightarrow y$

어디? 진짜?

- ✓ 원본식별
- ✓ **분석을 위한 구조 만들기**
- ✓ **데이터분석EDA & CDA**



- ✓ 모델링을 위한
데이터 구조 만들기
 - 모든 셀은 **값**이 있어야 한다.
 - 모든 값은 **숫자** 여야 한다.
 - (필요시) 숫자의 **범위**가 일치

- ✓ 모델 관리
- ✓ AI 서비스 구축

- ✓ 모델을 만들고
검증하기

문제가 해결 되었는가?

- ✓ 기술적 관점 평가
- ✓ 비즈니스 관점 평가

복습 – ML 알고리즘

✓알고리즘 한판 정리

	선형회귀	로지스틱회귀	KNN	SVM	Decision Tree	Random Forest	Gradient Boost (GBM, XGB, LGBM)
개념	✓오차를 최소화 하는 직선, 평면	✓오차를 최소화 하는 직선, 평면 ✓직선을 로지스틱 함수로 변환 (0~1 사이 값으로)	✓예측할 데이터와 train set과의 거리 계산 ✓가까운 [k개 이웃의 y]의 평균으로 예측	✓마진을 최대화 하는 초평면 찾기 ✓데이터 커널 변환	✓정보전달량 = 부모 불순도 - 자식 불순도 ✓정보 전달량이 가장 큰 변수를 기준으로 split	✓여러 개의 트리 ✓각각 예측 값의 평균 ✓행과 열에 대한 랜덤 : 조금씩 다른 트리들 생성	✓여러 개의 트리 ✓트리를 더해서 하나의 모델로 생성 ✓더해지는 트리는 오차를 줄이는 모델
전제 조건	✓NaN조치 ✓가변수화 ✓x들 간 독립	✓NaN조치 ✓가변수화 ✓x들 간 독립	✓NaN조치 ✓가변수화 ✓스케일링	✓NaN조치 ✓가변수화 ✓스케일링	✓NaN조치 ✓가변수화	✓NaN조치 ✓가변수화	✓NaN조치 ✓가변수화
성능	✓변수 선택 중요 ✓x가 많을 수록 복잡	✓변수 선택 중요 ✓x가 많을 수록 복잡	✓주요 hyper-parameter - n_neighbors : k 작을수록 복잡 - metric : 거리계산법	✓주요 hyper-parameter - C : 클수록 복잡 - gamma : 클수록 복잡	✓주요 hp - max_depth : 클수록 복잡 - min_samples_leaf : 작을수록 복잡	✓주요 hp 기본값으로도 충분! - n_estimators - max_features ✓기본값으로 생성된 모델 ==> 과적합 회피	✓주요 hp - n_estimators - learning_rate ✓XGB, LGBM : 과적합 회피를 위한 규제

복습 - 회귀모델 평가

오차의 크기

\hat{y} : 예측값		오차	제곱 오차	절대값 오차	오차율
y	\hat{y}	$y - \hat{y}$	$(y - \hat{y})^2$	$ y - \hat{y} $	$\left \frac{y - \hat{y}}{y} \right $
6	4				
5	6				
12	9				
2	2				

평균

MSE
RMSE

MAE

MAPE

평균 오차

평균 오차율

딥러닝 개념 - 학습 절차

✓ `model.fit(x_train, y_train)` 하는 순간...

단계① : 가중치에 (초기)값을 할당한다.

- 초기값은 랜덤으로 지정

단계② : (예측) 결과를 뽑는다.

단계③ : 오차를 계산한다.

단계④ : 오차를 줄이는 방향으로 가중치를 조정

- *Optimizer* : GD, Adam...

단계⑤ : 다시 단계①로 올라가 반복한다.

- *max iteration* 에 도달.(오차의 변동이(거의) 없으면 끝.)

- 가중치(weight)의 다른 용어 **파라미터(parameter)**

$$medv = 1 \cdot lstat + 3$$

medv	lstat	\hat{y}
20	10	13
10	11	14
8	15	18

$$mse = \frac{\sum (y - \hat{y})^2}{n} = \frac{7^2 + 6^2 + 8^2}{3}$$

$$w_1: 1 \rightarrow 0.8$$

$$w_0: 3 \rightarrow 3.3$$

$$medv = w_1 \cdot lstat + w_0$$


forward propagation

back propagation


딥러닝 개념 - 학습 절차

✓ 30번 학습(epochs = 30)하며 최적의 Weight를 찾아가는 과정

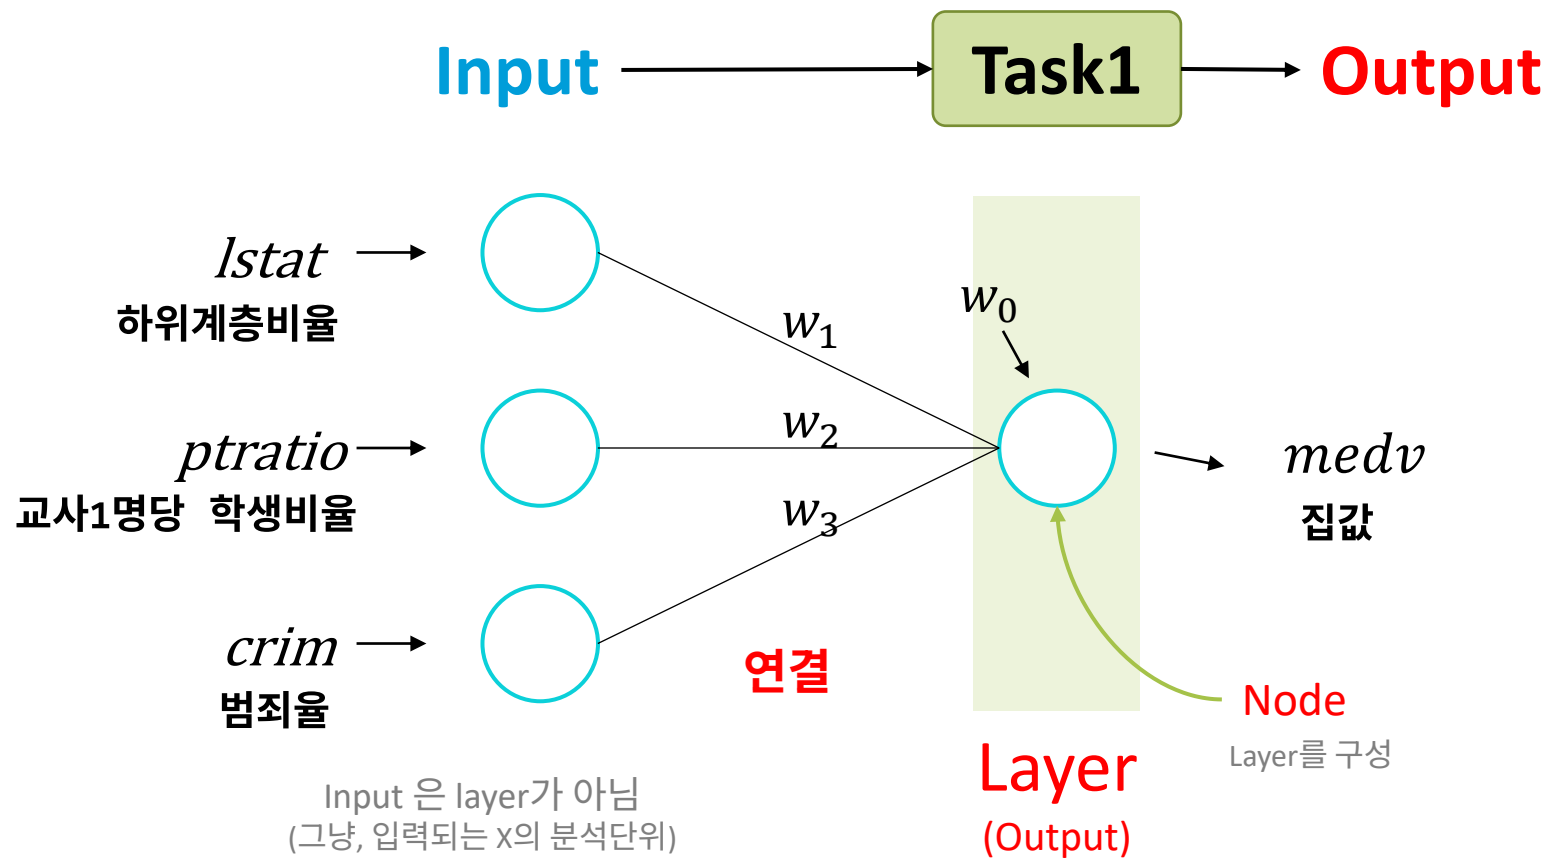
모델의 가중치가 업데이트되는 과정



모델의 오차가 줄어드는 과정(학습곡선)

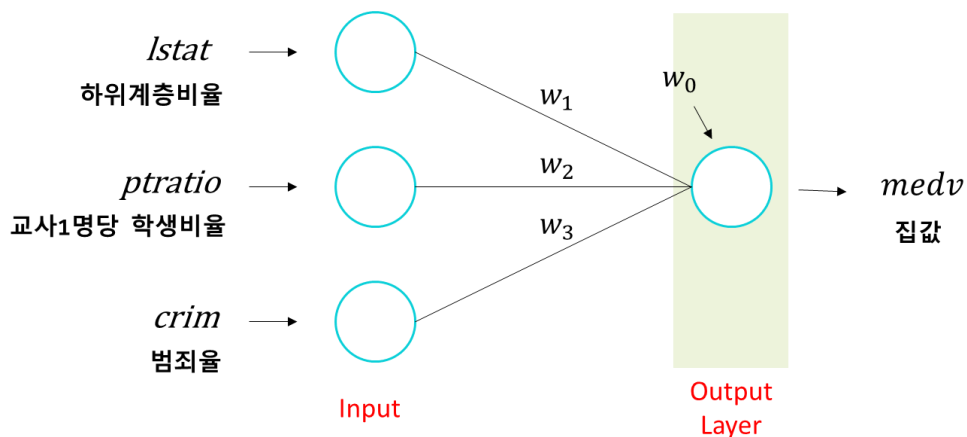


딥러닝 구조



$$medv = w_1 \cdot lstat + w_2 \cdot ptratio + w_3 \cdot crim + w_0$$

딥러닝 코드 - Dense



✓ **input_shape = (,)**

▪ 분석단위에 대한 shape

- 1차원 : (feature 수,)
- 2차원 : (rows, columns)

✓ **output**

▪ 예측 결과가 1개 변수(y가 1개 변수)

Python Code

```
# 메모리 정리
clear_session()

# Sequential 타입
model = Sequential([Dense(1, input_shape = (nfeatures,))])

# 모델요약
model.summary()
```

Annotations in the code: **output** points to the `1` in `Dense(1, ...)`, and **input** points to `nfeatures`. A **3** is also present near the `nfeatures` parameter.

Model: "sequential"

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 1)	4

```
=====
Total params: 4
Trainable params: 4
Non-trainable params: 0
=====
```


딥러닝 코드 - Compile

✓ 컴파일(Compile)

- 선언된 모델에 대해 몇 가지 설정을 한 후, 컴퓨터가 이해할 수 있는 형태로 변환하는 작업

Python Code

```
model.compile(optimizer = Adam(0.1), loss='mse')
```

✓ loss function(오차함수)

- 오차 계산을 무엇으로 할지 결정
- mse : mean squared error, 회귀모델은 보통 mse로 오차 계산


✓ optimizer

- 오차를 최소화 하도록 가중치를 조절하는 역할
- optimizer = 'adam' : learning_rate 기본값 = 0.001
- optimizer = Adam(lr = 0.1) : 옵션 값 조정 가능
 - lr과 learning_rate은 같지만, learning_rate 사용을 권장

딥러닝 코드 - 학습곡선

✓ .history

- 학습을 수행하는 과정 중에
- 가중치가 업데이트 되면서
- 그때그때마다의 성능을 측정하여 기록
- 학습 시 계산된 오차 기록
- 그것을 저장한 후 차트를 그리면...



Python Code


```
history = model.fit(x_train, y_train,
                    epochs = 20,
                    validation_split=0.2).history
```

```
Epoch 1/20
11/11 [=====] - 1s 31ms/step - loss: 571.5110 - val_loss: 577.0120
Epoch 2/20
11/11 [=====] - 0s 8ms/step - loss: 489.2647 - val_loss: 499.1079
Epoch 3/20
11/11 [=====] - 0s 11ms/step - loss: 418.2319 - val_loss: 432.6833
Epoch 4/20
11/11 [=====] - 0s 11ms/step - loss: 359.0570 - val_loss: 377.7811
Epoch 5/20
11/11 [=====] - 0s 7ms/step - loss: 309.7421 - val_loss: 332.4446
Epoch 6/20
11/11 [=====] - 0s 7ms/step - loss: 270.8658 - val_loss: 296.9759
Epoch 7/20
11/11 [=====] - 0s 6ms/step - loss: 240.5217 - val_loss: 270.1676
Epoch 8/20
11/11 [=====] - 0s 12ms/step - loss: 218.4201 - val_loss: 249.3737
Epoch 9/20
11/11 [=====] - 0s 7ms/step - loss: 200.8222 - val_loss: 233.2946
Epoch 10/20
11/11 [=====] - 0s 10ms/step - loss: 187.6137 - val_loss: 219.1513
Epoch 11/20
11/11 [=====] - 0s 7ms/step - loss: 175.6799 - val_loss: 208.9160
Epoch 12/20
11/11 [=====] - 0s 5ms/step - loss: 167.5694 - val_loss: 200.2585
Epoch 13/20
11/11 [=====] - 0s 7ms/step - loss: 160.8632 - val_loss: 193.0237
Epoch 14/20
11/11 [=====] - 0s 6ms/step - loss: 154.9114 - val_loss: 186.9379
Epoch 15/20
11/11 [=====] - 0s 9ms/step - loss: 149.6200 - val_loss: 181.1366
Epoch 16/20
11/11 [=====] - 0s 6ms/step - loss: 145.2706 - val_loss: 176.1777
Epoch 17/20
11/11 [=====] - 0s 7ms/step - loss: 141.4094 - val_loss: 172.2429
Epoch 18/20
11/11 [=====] - 0s 8ms/step - loss: 138.0926 - val_loss: 168.4736
Epoch 19/20
11/11 [=====] - 0s 7ms/step - loss: 135.0007 - val_loss: 164.8660
Epoch 20/20
11/11 [=====] - 0s 13ms/step - loss: 131.7069 - val_loss: 161.3870
```


딥러닝 코드 - 학습곡선

✓ 바람직한 곡선의 모습


- Epoch가 증가하면서 Loss가 큰 폭으로 축소
- 점차 Loss 감소 폭이 줄어들면서 완만해짐.




- Loss가 줄어들기는 하나, 들쭉날쭉
→ Learning_rate을 줄여 보시다.



- Val_loss가 줄어들다가 다시 상승(과적합)
→ Epochs와 learning_rate을 조절해 보시다.



딥러닝 구조 - Hidden Layer



✓ layer 여러 개 : **리스트[]** 로 입력

✓ hidden layer

- input_shape 는 첫번째 layer만 필요
- activation
 - 히든 레이어는 활성화함수를 필요로 합니다.
 - 활성화함수는 보통 'relu'를 사용

✓ output layer

- 예측 결과가 1개

Python Code

```
# 메모리 정리
clear_session()

# Sequential 타입 모델 선언
model3 = Sequential([Dense(2, input_shape = (nfeatures,)
                        , activation = 'relu')
                    , Dense(1)])

# 모델요약
model3.summary()
```

Model: "sequential"

Layer (type)	Output Shape	Param #
dense (Dense)	(None, 2)	26
dense_1 (Dense)	(None, 1)	3
Total params: 29		
Trainable params: 29		
Non-trainable params: 0		


활성화 함수 Activation Function

✓ 그래서 활성화 함수는...

- Hidden Layer에서는 : 선형함수를 비선형 함수로 변환
- Output Layer에서는 : 결과값을 다른 값으로 변환해 주는 역할
 - 주로 분류 Classification 모델에서 필요


Sigmoid

$$\sigma(x) = \frac{1}{1+e^{-x}}$$




tanh

$$\tanh(x)$$




ReLU

$$\max(0, x)$$



Leaky ReLU

$$\max(0.1x, x)$$




Maxout

$$\max(w_1^T x + b_1, w_2^T x + b_2)$$

ELU

$$\begin{cases} x & x \geq 0 \\ \alpha(e^x - 1) & x < 0 \end{cases}$$



Hidden layer
국룰



요약 : 회귀 모델링

✓ 딥러닝 전처리

- NaN 조치, 가변수화, 스케일링

✓ Layer

- 첫번째 Layer는 input_shape를 받는다.(분석단위의 shape)
 - 2차원 데이터셋의 분석단위 1차원 → shape는 (feature수,)
- Output layer의 node 수 : 1
- Activation Function
 - Hidden layer에 필요 :
 - 비선형 모델로 만들려고 → hidden layer를 여럿 쌓아서 성능을 높이려고.
 - 회귀 모델링에서 Output Layer에는 활성화 함수 필요하지 않음!

구분	Hidden Layer	Output Layer		Compile	
	Activation	Activation	Node수	optimizer	loss
Regression	relu	X	1	adam	mse